

1 - Considere padrões textuais comuns em sistemas de informação brasileiros. Para cada item, **escreva a expressão regular** que valida exatamente o formato descrito, respeitando as restrições indicadas. Use âncoras ^ e \$ em todos os itens

a) Telefone brasileiro com DDD

(XX) XXXXX-XXXX (celular) ou (XX) XXXX-XXXX (fixo)

(11) 99999-1234 / (21) 3333-5678

11 99999-1234 / (1) 9999-1234

b) Placa de veículo

Formato antigo ABC-1234 ou Mercosul ABC1D23

ABC-1234 / BRA1A23

abc-1234 / ABCD-123

c) Senha forte

Mínimo de 10 caracteres, contendo pelo menos: uma letra maiúscula, uma minúscula, um dígito e um caractere especial entre !@#\$%^&*()

2 - Calcule a distância de Levenshtein entre "DOMINGO" e "DEMONIO". Preencha toda a matriz, informe a distância final e a sequência de operações.

3 - Considere o Corpus abaixo (stopwords removidas):

D1	processamento linguagem natural processamento texto
D2	aprendizado maquina processamento linguagem natural
D3	aprendizado profundo redes neurais aprendizado
D4	linguagem natural geracao texto redes neurais texto
D5	redes neurais aprendizado maquina processamento

a) Calcule TF, df, IDF e TF-IDF de cada termo para D1 e D2. Use $IDF = \log_2(N/df)$ com $N=5$.

4 - Considere o corpus, a consulta "pln útil" e os parâmetros: $k1 = 1.2$ e $b = 0.75$

CORPUS

D1: "pln aprendizado maquina" / D2: "aprendizado profundo"

D3: "pln útil útil útil"

a) Calcule o df de cada termo da consulta e o IDF de cada termo

b) Calcule o score BM25 para cada documento *

c) Ordene os documentos por relevância

5 - Os vetores de quatro palavras em um espaço 3D estão dados abaixo. Calcule a norma de cada vetor e a similaridade de cosseno entre os três pares indicados. Ao final, ordene os pares do mais similar ao menos similar.

Palavra	v[1]	v[2]	v[3]	Norma v
linguagem	2	1	0	?
idioma	3	2	1	?
computador	0	1	3	?
maquina	1	1	2	?

Par	Produto interno (a . b)	a * b	Similaridade de cosseno
linguagem x idioma			
linguagem x computador			
idioma x maquina			